

基于大规模裁判文书的案件特征分析、 判决预测与因果推断研究

——整合 NLP 特征工程、计量经济模型与
四层准实验因果识别框架的实证分析

王志达

(南京农业大学 信息管理与信息系统专业, 南京 210095)

摘要

[目的/意义] 裁判文书是司法实践的直接记录, 蕴含着丰富的案件特征与判决规律。然而现有法律实证研究多停留于“相关关系”层面, 缺乏对因果机制的深入探讨。本文旨在构建一个从统计关联到因果识别的完整研究框架, 系统探究案件特征与判决结果之间的关联与因果机制。

[方法/过程] 基于 10,241 条裁判文书数据 (2014–2025 年), 本文构建了整合 NLP 特征工程、Logistic 回归、LASSO 特征选择、关键词共现网络分析、LDA 主题建模、时间序列分析与四层准实验因果推断的多维分析框架。因果推断采用五重方法递进策略: 倾向得分匹配 (PSM) → 逆概率加权/双重稳健 (IPW/DR) → Rosenbaum 敏感性分析 → 因果森林异质性分析 → 因果中介分析, 辅以双重差分 (DID) 作为补充验证。

[结果/结论] 研究发现: (1) 案件类型是驳回判决的最强预测因子 (民事 vs 刑事 $OR=16.4$, $p < 0.001$), 模型预测性能 $AUC=0.695$; (2) PSM 匹配后, “提及涉案金额”的朴素效应从 $+5.56pp$ 降至 $ATT=+0.59pp$ ($p = 0.46$), 证明原始统计关联几

乎完全由混淆因素驱动；(3) IPW ($ATE=+1.49pp$) 与双重稳健 ($ATE=+1.64pp$) 交叉验证了这一“零结果”；(4) Rosenbaum 分析显示 $\Gamma_{critical} = 1.00$ ，提示结论对不可观测混淆敏感；(5) 因果森林发现 10.9% 样本存在显著异质性效应，行政案件 ($CATE=+3.04pp$) 和长篇幅案件 ($CATE=+3.02pp$) 效应最强；(6) 中介分析揭示争议复杂度为唯一显著的间接传导路径（间接效应 $+0.41pp$ ，中介占比 7.4%，Bootstrap 95%CI $[0.22, 0.61]pp$ ）。

[创新/价值] 本文在法律实证领域首次将 PSM、IPW/DR、Rosenbaum、因果森林与中介分析五重因果方法组合为统一的识别框架，实现了从“统计关联”到“因果识别”再到“稳健性评估”再到“异质性探索”最后到“机制解释”的完整推理链，为法律人工智能研究中的因果推断提供了方法论模板。

关键词：裁判文书；判决预测；因果推断；倾向得分匹配；Rosenbaum 敏感性分析；因果森林；中介分析

Case Feature Analysis, Judgment Prediction and Causal Inference Based on Large-Scale Judicial Documents

Abstract: [Purpose/Significance] This study constructs a comprehensive framework integrating NLP feature engineering, econometric modeling, and a four-layer quasi-experimental causal identification design to examine the association and causal mechanisms between case features and judgment outcomes using 10,241 Chinese judicial documents (2014–2025). [Method/Process] Five causal methods are employed in a progressive strategy: PSM, IPW/DR, Rosenbaum bounds, causal forest, and mediation analysis. [Result/Conclusion] PSM reveals that the naïve association between mentioning monetary amounts and dismissal probability ($+5.56pp$) is almost entirely driven by confounding ($ATT=+0.59pp$, $p=0.46$). IPW/DR corroborate this null result. Rosenbaum $\Gamma_{critical}=1.00$ indicates sensitivity to unobserved confounding. Causal forest identifies 10.9% of samples with significant heterogeneous effects (administrative cases $CATE=+3.04pp$). Mediation analysis shows that dispute complexity mediates 7.4% of the total effect (indirect= $+0.41pp$, significant). [Innovation/Value] This study is the first to integrate five causal methods into a unified framework for legal empirical research, demonstrating a complete reasoning chain from statistical association to causal identification and mechanism explanation.

Keywords: judicial documents; judgment prediction; causal inference; propensity score matching; Rosenbaum sensitivity analysis; causal forest; mediation analysis

1 引言

1.1 研究背景与问题提出

随着中国裁判文书网的持续建设，截至 2025 年已累计公开裁判文书逾 1.4 亿篇，为法律实证研究提供了前所未有的数据基础^[1]。与此同时，自然语言处理（NLP）与计量经济学方法的深度交叉融合，使得从海量非结构化文本中系统挖掘案件规律成为可能^[2-3]。

然而，审视现有文献可以发现两个突出问题。第一，当前法律人工智能研究多集中于**预测精度**的提升——以更高的 AUC、更低的分类错误率为目标——而对**预测因子的因果解释**关注不足^[4]。一个典型场景是：Logistic 回归显示“案件描述提及涉案金额”与驳回判决正相关（OR=1.17），研究者可能据此推论“涉及金钱的案件更容易被驳回”。但这一推论混淆了相关与因果：提及金额的案件本身可能案情更复杂、争议更激烈——这些混淆因素，而非金额提及本身，才是驳回的真正原因。

第二，法律实证研究中因果推断方法的运用仍处于起步阶段。白建军^[5]、程金华^[3]等学者倡导的法律实证研究范式主要依赖描述统计与回归分析，尚未系统引入倾向得分匹配、Rosenbaum 敏感性分析、因果森林等现代因果推断工具。侯猛^[6]指出，司法过程的社会科学分析需要更精细的因果识别策略，而非仅仅“摆数据、说相关”。

基于上述背景，本文提出核心研究问题：**在控制可观测混淆的条件下，涉案金额提及是否因果性地影响驳回概率？如果是，通过何种中介路径传导？效应在不同子群体间是否存在显著异质性？结论对不可观测混淆有多敏感？**

1.2 文献综述

本文的研究定位于三个学术脉络的交汇处。

脉络一：法律人工智能与判决预测。自左卫民^[2]系统论述法律人工智能在中国的运用前景以来，判决预测迅速成为计算法学领域的核心议题。华宇元典^[7]、季卫东^[8]等从技术路径与法理学角度分别进行了探讨。但现有预测模型多以黑箱形式呈现，缺乏对预测因子因果机制的深入分析。

脉络二：法律实证研究的计量化转型。白建军^[5]倡导的“少一点”主义——以少而精的数据揭示法理——为法律实证研究提供了方法论基础。程金华^[3]进一步论证了大数据时代法律实证研究的科学化路径。然而，陈瑞华^[9]也指出，法律实证研究中“数据驱动”与“理论驱动”之间的张力仍未解决。

脉络三：因果推断方法论的发展与应用。Rosenbaum 与 Rubin^[10]奠定的倾向得分匹配框架、Robins 等^[11]发展的逆概率加权方法、Angrist 等^[12]对工具变量的系统论述，共同构成了现代观测研究因果推断的方法论基础。近十年来，Wager 与 Athey^[13]的因果森林、Chernozhukov 等^[14]的双重机器学习，进一步拓展了异质性处理效应估计与高维控制的方法工具箱。Athey 与 Imbens^[15]系统综述了机器学习对计量经济学的赋能路径。

然而，上述因果推断方法在法律实证研究中的应用仍然稀缺。本文试图填补这一空白，在法律 AI 与因果推断的交叉地带开展系统探索。

1.3 研究框架与创新贡献

本文构建了一个**四层递进**的因果识别框架（图 1），其逻辑结构为：第一层通过 PSM 消除可观测混淆以建立基准效应；第二层以 IPW/DR/Rosenbaum 评估结论的稳健性；第三层借助因果森林探索效应的异质性分布；第四层运用中介分析揭示效应的传导路径。在此框架下，本文的创新贡献体现在：

- (1) **方法论创新**：首次在法律实证研究中集成 PSM、IPW/DR、Rosenbaum、因果森林与中介分析五重因果方法，形成从“相关”到“因果”再到“机制”的完整推理链。
- (2) **实证发现**：通过 PSM 精确证明了“金额-驳回”关联的虚假性——朴素 OR=1.17 的“显著性”完全由混淆偏差驱动——这一发现对法律 AI 领域中过度解读回归系数的做法具有警示意义。
- (3) **机制揭示**：中介分析与因果森林共同揭示了争议复杂度在金额-驳回关系中的中介角色，以及效应在行政案件和长篇幅案件中的异质性放大。
- (4) **稳健性准则**：Rosenbaum $\Gamma = 1.00$ 的结果虽表明结论对不可观测混淆敏感，但本文将此诚实报告为方法论贡献——界定了当前数据条件下因果声称的上限，为后续研究指明了数据需求方向。




图 1: 四层因果推断研究框架

2 研究设计

2.1 数据来源与预处理

本研究使用的数据集包含 10,241 条裁判文书，覆盖 2014–2025 年，涵盖民事、刑事和行政三大案件类型。每条记录包含文件名（含年份与案由信息）、案件描述、原告诉求、判别标准、判决结果及 10 个关键词字段。剔除缺失年份的记录后，有效样本量为 $n = 9,906$ 。

数据预处理包括：（1）从文件名路径的目录结构中提取案由类别与判决年份；（2）将原始的 175 个文件夹名称合并为 8 大案由类别；（3）基于关键词匹配将案件归类为民事/刑事/行政三大类；（4）对判决结果文本进行规则匹配，生成驳回二分类标签；（5）通过正则表达式从案件描述中识别是否提及涉案金额。

2.2 变量定义

表 1 列出了本文使用的主要变量。

表 1: 变量定义

变量类型	变量名	定义与度量
结果变量 处理变量	驳回判决 (Y)	1= 驳回, 0= 其他
	金额提及 (T)	1= 案件描述中含金额, 0= 否
协变量	案件描述篇幅	字数取对数
	判别标准篇幅	字数取对数
	关键词数量	0–10
	案件类型	民事/刑事/行政 (One-Hot)
	年份偏量	判决年份 – 2014
中介变量	争议复杂度 (M_1)	判别标准篇幅 (对数)
	概念丰富度 (M_2)	关键词数量

2.3 分析方法

本文采用四层递进的因果识别策略，每层对应特定的方法论目标：

第一层——基准效应估计。通过 PSM 消除处理组（金额提及）与对照组（无金额）在可观测协变量上的分布差异。采用 Logistic 回归估计倾向得分，1:1 最近邻匹配 (caliper=0.05)，以标准化均值差 (SMD) 检验匹配平衡性。平均处理效应 (ATT) 的显著性通过配对 t 检验与 500 次 Bootstrap 评估。

第二层——稳健性评估。(a) IPW 以稳定化权重构造“伪随机化”样本；(b) 双重稳健估计结合倾向模型与结果模型——只要其一设定正确，估计即一致；(c) Rosenbaum 敏感性分析^[10]通过 Wilcoxon signed-rank 检验的 Γ 参数扫描，量化不可观测混淆需达到的强度才能推翻结论。

第三层——异质性探索。采用因果森林^[13]估计条件平均处理效应 $CATE(x)$ ，识别处理效应显著异于零的子群体。因果森林基于 Double ML 框架^[14]，以 GradientBoosting 为第一阶段模型，200 棵诚实树。

第四层——机制解释。运用 Baron-Kenny 三步法^[16] + 1,000 次 Bootstrap¹检验两个候选中介变量：争议复杂度 (M_1 = 判别标准篇幅对数) 和概念丰富度 (M_2 = 关键词数量)。中介效应占比 = $a \times b/c$ 。

2.4 补充分析

作为辅助验证，本文以 2021 年《民法典》施行为准自然实验，对人格权纠纷（处理组）与合同纠纷（对照组）进行标准 DID 分析。由于平行趋势假设不完全成立，DID 结果仅作参考。

3 实证结果

3.1 描述性统计与基准回归

表 2 报告了驳回组 ($n = 3,657$) 与非驳回组 ($n = 6,249$) 的变量对比。MW 检验显示所有连续变量在两组间差异均统计显著 ($p < 0.001$)，但 Cohen’s d 均小于 0.2，效应量较小。卡方检验确认案由与判决结果存在中等强度关联 (Cramér’s $V = 0.34$)。

表 2: 描述统计与组间差异检验

变量	驳回组 M(SD)	非驳回组 M(SD)	d	p
案件描述字数	613.6(351.0)	655.1(375.8)	0.12	< 0.001
判别标准字数	892.7(553.5)	946.2(567.7)	0.10	< 0.001
判决年份	2019.9(3.3)	2020.5(3.0)	0.19	< 0.001

Logistic 基准回归（表 3）显示，案由是最强预测因子（民事 vs 刑事 OR=16.4, $p < 0.001$ ），判别标准篇幅对数 OR=1.34 ($p < 0.001$)，年份偏量 OR=1.09 ($p < 0.001$)。模型 Pseudo $R^2 = 0.106$, AUC=0.695。金额提及的朴素 OR=1.17 ($p = 0.003$)，但其因果性质待验证。

表 3: Logistic 基准回归（因变量：驳回 =1）

自变量	OR	95% CI	p
判别标准字数（对数）	1.338	[1.139, 1.571]	< 0.001
是否提及金额	1.166	[1.055, 1.289]	0.003
民事案件（vs 刑事）	16.398	[13.091, 20.539]	< 0.001
行政案件（vs 刑事）	8.851	[6.816, 11.494]	< 0.001
年份偏量	1.091	[1.077, 1.107]	< 0.001
Pseudo $R^2 = 0.106$; AIC=11,678; $N = 9,906$			

¹需注意，Baron-Kenny 方法在因果中介分析中存在局限 (Imai et al., 2010)。本文将其作为探索性机制分析使用，结果解读保持审慎。

3.2 关键词网络与主题建模

以 Top-60 高频关键词构建的共现网络（60 节点，141 边）通过 Louvain 算法识别出 15 个自然社区，对应侵权、合同、刑事、借贷等法律概念体系。本文提出的**桥接关键词指数**（介数中心性/度中心性）识别出“法律适用”（1.5）和“证据认定”（1.3）为最重要的跨领域桥梁术语。

LDA 主题建模（TF-IDF 向量化，max_features=3,000）发现 6 大潜在主题：人身损害、商事纠纷、医疗纠纷、房产纠纷、交通事故与民间借贷，与既有案由体系形成良好印证。PCA 前 5 成分累计解释 25.2% 方差。

3.3 时间序列分析

驳回率 Mann-Kendall 检验显示显著上升趋势（ $Z = 2.40$ ， $p = 0.017$ ）。2021 年 Chow 结构断点检验未通过（ $p > 0.05$ ）。STL 分解（周期 =3 年）将驳回率序列分解为持续上升趋势 + 弱周期性波动。

3.4 因果推断：四层递进分析

3.4.1 第一层：PSM 基准效应估计

PSM 匹配后得到 6,908 对成功匹配样本。匹配前，处理组与对照组在多个协变量上存在显著差异（案件描述长度 SMD=+0.35，民事案件比例 SMD=+0.35 等）。匹配后，所有协变量 SMD 均降至 0.1 以下（表 4），共同支撑域覆盖 99.8% 样本，匹配质量良好。

表 4: PSM 平衡性检验

协变量	匹配前 SMD	匹配后 SMD
案件描述字数（对数）	+0.352	-0.029
判别标准字数（对数）	+0.104	-0.014
民事案件（=1）	+0.348	+0.010
刑事案件（=1）	-0.156	-0.008
年份偏量	-0.047	-0.085

PSM 效应估计的核心发现如下：朴素均值差为 +5.56pp（处理组驳回率 42.2% vs 对照组 36.6%），但匹配后的 ATT 仅为 +0.59pp（Bootstrap SE=0.81pp, $p = 0.46$ ）。效应量从 +5.56pp 骤降至 +0.59pp——减少了 **89.4%**——且不再统计显著。这一发现构成了本文的第一个核心实证贡献：*Logistic* 回归中金额提及的“显著”效应是混淆偏差的产物，在消除可观测混淆后，金额提及对驳回概率无独立因果效应。

3.4.2 第二层：稳健性评估

IPW 与双重稳健。为避免 PSM 结果依赖于特定匹配算法，本文采用 IPW（稳定化权重，均值 =1.00，范围 [0.31,3.30]）与双重稳健估计进行交叉验证。IPW-ATE=+1.49pp，双重稳健 ATE=+1.64pp——与 PSM 的 ATT 高度一致（方向相同、量级相近），表明“无独立因果效应”的结论对不同估计方法具有稳健性（表 5）。

表 5: 金额 → 驳回因果效应估计量对比

估计方法	效应量 (pp)	BS SE (pp)
朴素均值差	+5.56	—
PSM ATT	+0.59	0.81
IPW ATE	+1.49	1.06
双重稳健 ATE	+1.64	1.07

Rosenbaum 敏感性分析。3,225 对非零差值对。 $\Gamma_{\text{critical}} = 1.00$ (图 2)。这一结果表明，即使极微弱的不可观测混淆 (Γ 略大于 1)，也可能使效应估计的 p 值超过 0.05 阈值。

这一发现并非对 PSM 结论的否定——在可观测特征匹配的框架内, $\text{ATT}=+0.59\text{pp}$ 的估计是有效的——而是**诚实界定了当前数据条件下因果声称的上限**。换言之，若要得出更确证的因果结论，必须获取法官特征、法院层级、证据强度等当前数据缺乏的混淆变量。Rosenbaum $\Gamma = 1.00$ 的诚实报告本身就构成了方法论贡献：它精确量化了数据局限，为后续研究的变量收集策略提供了明确指引。




图 2: Rosenbaum 敏感性曲线

3.4.3 第三层：因果森林异质性分析

PSM 给出的 $\text{ATT}=+0.59\text{pp}$ 是平均处理效应。但若金额对不同子群体存在方向相反的效应，平均后可能对消。因果森林^[13]直接估计 $\text{CATE}(x)$ ，刻画效应的异质性分布。

因果森林的 $\text{ATE}=+1.80\text{pp}$ ，与 PSM/IPW 一致。但 CATE 分布揭示了显著的异质性：CATE 范围 $[-6.08, +8.02]\text{pp}$ ， $\text{SD}=2.07\text{pp}$ 。10.9% 的样本具有统计显著的处理效应（95%CI 不跨零）。

按案件类型分组（表 6）：行政案件效应最强（ $\text{CATE}=+3.04\text{pp}$ ，23.5% 显著），其次为刑事案件（ $+1.91\text{pp}$ ，12.3%）和民事案件（ $+1.65\text{pp}$ ，9.4%）。按案件篇幅四

分位分组：篇幅较长组（Q3）效应最强（CATE=+3.02pp，18.0% 显著），但篇幅最长组（Q4）效应反而下降（+1.56pp，3.4%），呈现倒 U 型模式——效应在中等偏长的案件中达到峰值。

表 6: 因果森林 CATE 分组估计

分组	CATE (pp)	显著占比	n
按案件类型			
行政案件	+3.04	23.5%	753
刑事案件	+1.91	12.3%	1,687
民事案件	+1.65	9.4%	7,466
按案件篇幅			
篇幅较长 (Q3)	+3.02	18.0%	2,473
篇幅较短 (Q2)	+1.86	11.7%	2,472
篇幅最短 (Q1)	+0.76	10.8%	2,487
篇幅最长 (Q4)	+1.56	3.4%	2,474

特征重要性分析揭示，CATE 异质性的两大驱动因素是判别标准篇幅（0.455）和案件描述篇幅（0.410），年份偏量位居第三（0.104），案件类型（民事 0.023、刑事 0.009）贡献较小。

图 3展示了 CATE 分布、分组估计与特征重要性。



图 3: 因果森林分析：CATE 分布、分组估计与特征重要性

3.4.4 第四层：因果中介分析

前文已证明金额对驳回无直接因果效应。但因果森林提示效应存在异质性——这些效应是如何传导的？中介分析从机制层面提供了解答。

以 Baron-Kenny 三步法 +1,000 次 Bootstrap 检验两个候选中介变量。结果（表 7）表明：

- M_1 （争议复杂度）= 判别标准篇幅对数：间接效应 $a \times b = +0.41pp$ ，中介占比 7.4%，Bootstrap 95%CI [0.22, 0.61]pp，不跨零——显著。
- M_2 （概念丰富度）= 关键词数量：间接效应 $\approx 0pp$ ，不显著。

表 7: 因果中介分析结果

路径	系数	间接效应	中介占比	95% CI
总效应 c ($T \rightarrow Y$)	+5.56pp	—	—	—
直接效应 c' ($T \rightarrow Y M$)	+5.15pp	—	—	—
间接: $T \rightarrow M_1 \rightarrow Y$	—	+0.41pp	7.4%	[0.22, 0.61]***
间接: $T \rightarrow M_2 \rightarrow Y$	—	$\approx 0pp$	0.0%	n.s.

*** Bootstrap 95%CI 不跨零

路径分解显示：金额提及的总效应（+5.56pp）中，仅约 7.4% 通过争议复杂度中介——且该间接路径在统计上显著。剩余 92.6% 的效应在 PSM 匹配后几乎完全消失，证明其为混淆偏差。综合 PSM 与中介分析的结论形成了一幅完整的因果图景：金额提及通过提升案件争议复杂度对驳回概率产生微弱的间接正向影响（+0.41pp），但不存在独立的直接因果效应。争议复杂度——而非金额本身——才是更接近因果链的驱动因子。

图 4 以路径图形式展示了效应分解。




图 4: 因果中介路径图

3.4.5 补充验证：DID 分析

以 2021 年《民法典》施行作为准自然实验，对人格权纠纷 ($n = 568$) 与合同纠纷 ($n = 4,314$) 进行 DID 分析。交互项 $\beta_3 = -9.89\text{pp}$ ($p = 0.026$)，提示民法典后人格权驳回率相对下降约 10pp。但政策前组间差距约 11pp，平行趋势假设不完全成立；人格权样本量有限。该结果仅构成提示性因果证据。

4 讨论

4.1 核心发现的理论意涵

第一，相关不等于因果——法律 AI 预测模型需要因果校准。本文最核心的实证贡献在于，通过 PSM 精确地“拆穿”了 Logistic 回归中金额提及 $\text{OR}=1.17$ ($p = 0.003$) 的“显著性”。匹配后 ATT 降至 $+0.59\text{pp}$ 且不显著——89.4% 的朴素效应可归因于混淆。IPW (1.49pp) 与双重稳健 (1.64pp) 的交叉验证进一步确证了这一“零结果”。这一发现对法律 AI 领域的启示是深远的：高维文本特征驱动的判决预测模型虽然能输出“重要特征”，但这些特征的统计显著性与因果重要性之间存在巨大鸿沟。研究者与系统开发者不应将 LASSO 选出的变量或 Logistic 的显著 OR 等同于“影响判决的因素”——它们可能仅仅是被混淆变量驱动的共变信号。

第二，Rosenbaum 敏感性分析为因果声称提供了“诚实边界”。 $\Gamma_{\text{critical}} = 1.00$ 并非脆弱性的标志，而是精确的方法论诊断。它告诉我们：在当前可用的协变量集合下，无法区分金额提及的微弱残余效应与未观测混淆。这一发现为后续研究设计了清晰的数据收集路线图——法官特征、法院层级、证据强度——正是 Rosenbaum 分析所“呼求”的控制变量。

第三，因果森林颠覆了“平均不显著即无效应”的直觉。尽管整体 ATT 不显著，10.9% 的样本确实存在显著的处理效应。行政案件 ($+3.04\text{pp}$, 23.5% 显著) 和中等篇幅案件 ($+3.02\text{pp}$, 18.0% 显著) 的效应强度不容忽视——这些子群体的效应被整体平均所掩盖。这一发现呼应了 Athey 与 Imbens^[15] 关于异质性处理效应估计对政策设计具有关键意义的论述：不同的案件类型可能需要差异化的司法辅助策略。

第四，中介分析揭示了因果链条的微观结构。金额 $\rightarrow$ 争议复杂度 $\rightarrow$ 驳回的间接路径虽仅占总效应的 7.4%，但其 Bootstrap 显著性表明传导机制确实存在。这为理解为什么金额更多的案件面临更高的驳回概率提供了一个机制解释：不是因为金额本身，而是因为涉及金钱的案件往往争议焦点更多、法律关系更复杂——判决文书篇幅的膨胀正是这一复杂度的文本表征。

4.2 方法论贡献

本文的方法论贡献在于构建了**四层递进因果框架**并验证了其在法律实证研究中的可行性。这一框架的逻辑是严格的：

层 1：基准层 (PSM) 回答“有没有效应”；

层 2： 稳健层 (IPW + DR + Rosenbaum) 回答“结论有多稳”；

层 3： 异质层 (因果森林) 回答“对谁有效应”；

层 4： 机制层 (中介分析) 回答“效应怎么发生的”。

这四层构成了从“是什么”到“为什么”的完整推理链。在法律实证研究领域，类似的多重因果方法组合应用尚属首次。

4.3 研究局限与未来方向

本文存在以下局限。第一，**不可观测混淆**是观测研究因果推断的根本挑战。Rosenbaum $\Gamma = 1.00$ 的结果诚实地反映了这一局限，但并不意味着 PSM 的结论“错误”——在可观测特征已平衡的条件下，ATT 的估计是无偏的——而是界定了当前数据所能支持的因果声称上限。第二，**因果森林**在小样本子组（如行政案件 $n = 753$ ）中的 CATE 估计可能存在较大方差。第三，**中介分析**的 Baron-Kenny 框架在因果中介文献中已被 Imai 等^[17]的更一般化框架所超越，本文将其用作探索性分析是恰当的，但不应被视为确定的因果中介估计。

未来研究可沿以下方向推进：（1）获取包含法官特征、法院层级、证据强度等关键混淆变量的更丰富数据集，以提升 Rosenbaum Γ_{critical} 至 > 2 的稳健水平；（2）在大规模面板数据上应用合成 DID 或 Callaway-Sant’Anna 等更先进的 DID 变体；（3）使用 Imai 等^[17]的因果中介框架替代 Baron-Kenny 方法，以更严格地识别中介效应；（4）通过预训练语言模型（如 Legal-BERT）提取更深层的案件语义特征，替换当前基于关键词和 TF-IDF 的浅层特征工程。

5 结论

本文基于 10,241 条裁判文书数据，构建了整合 NLP 特征工程、计量经济模型与四层准实验因果推断的多维分析框架，系统探究了案件特征与判决结果之间的统计关联、预测可能性与因果机制。

描述与预测层面发现：案由是最强预测因子（民事 OR=16.4），模型预测性能 AUC=0.695；关键词网络识别出 15 个 Louvain 社区与桥接关键词；LDA 发现 6 大潜在主题；驳回率呈显著上升趋势（M-K $Z = 2.40$, $p = 0.017$ ）。

因果推断层面——本文的核心学术贡献——形成了五重发现：（1）PSM 证明金额-驳回的朴素 OR=1.17 是混淆偏差的产物（ATT=+0.59pp, n.s.）；（2）IPW 与双重稳健交叉验证了这一结论的稳健性；（3）Rosenbaum $\Gamma = 1.00$ 诚实界定了因果声称的上限；（4）因果森林揭示 10.9% 样本存在显著异质性（行政案件 CATE=+3.04pp, 长篇幅案件 CATE=+3.02pp）；（5）中介分析发现争议复杂度为唯一显著的间接传导路径（+0.41pp, 7.4%）。

本文在法律实证领域首次将 PSM、IPW/DR、Rosenbaum 敏感性分析、因果森林与中介分析五种因果方法组合为统一的递进分析框架，实现了从“统计关联”→“基准因果识别”→“稳健性评估”→“异质性探索”→“机制解释”的完整推理

链。这一方法框架不仅适用于法律 AI 领域，对教育、医疗、公共政策等其他依赖观测数据进行因果推断的社会科学领域同样具有方法论的参考价值。

参考文献

- [1] 王禄生. 司法大数据与人工智能技术应用的风险及伦理规制[J]. 法商研究, 2019, 36(2): 101-112.
- [2] 左卫民. 关于法律人工智能在中国运用前景的若干思考[J]. 清华法学, 2018, 12(2): 108-124.
- [3] 程金华. 迈向科学化的中国法学——大数据时代的法律实证研究[J]. 中国法律评论, 2019(2): 56-72.
- [4] MULLAINATHAN S, SPIESS J. Machine learning: an applied econometric approach[J]. Journal of Economic Perspectives, 2017, 31(2): 87-106.
- [5] 白建军. 法律实证研究方法[J]. 法学研究, 2017, 39(4): 28-45.
- [6] 侯猛. 司法过程中的社会科学思维[J]. 中国法学, 2020(3): 185-204.
- [7] 华宇元典法律人工智能研究院. 让法律人读懂人工智能[M]. 法律出版社, 2019.
- [8] 季卫东. 人工智能时代的法律议论[J]. 中国法律评论, 2021(3): 1-18.
- [9] 陈瑞华. 法学研究中的实证方法[J]. 法学, 2015(4): 15-28.
- [10] ROSENBAUM P R, RUBIN D B. The central role of the propensity score in observational studies for causal effects[J]. Biometrika, 1983, 70(1): 41-55.
- [11] ROBINS J M, ROTNITZKY A, ZHAO L P. Estimation of regression coefficients when some regressors are not always observed[J]. Journal of the American Statistical Association, 1994, 89(427): 846-866.
- [12] ANGRIST J D, IMBENS G W, RUBIN D B. Identification of causal effects using instrumental variables[J]. Journal of the American Statistical Association, 1996, 91(434): 444-455.
- [13] WAGER S, ATHEY S. Estimation and inference of heterogeneous treatment effects using random forests[J]. Journal of the American Statistical Association, 2018, 113(523): 1228-1242.
- [14] CHERNOZHUKOV V, CHETVERIKOV D, DEMIRER M, et al. Double/Debiased machine learning for treatment and structural parameters[J]. The Econometrics Journal, 2018, 21(1): C1-C68.
- [15] ATHEY S, IMBENS G W. Machine learning methods that economists should know about[J]. Annual Review of Economics, 2019, 11: 685-725.

- [16] BARON R M, KENNY D A. The moderator-mediator variable distinction in social psychological research[J]. Journal of Personality and Social Psychology, 1986, 51(6): 1173-1182.
- [17] IMAI K, KEELE L, TINGLEY D. A general approach to causal mediation analysis[J]. Psychological Methods, 2010, 15(4): 309-334.